

다층 퍼셉트론과 LSTM 순환 신경망을 이용한 온라인 쇼퍼 구매 의도의 실시간 예측

C. Okan Sakar · S. Olcay Polat · Mete Katircioglu · Yomi Kastro

Neural Computing and Applications (2019) 31:6893–6908 · DOI: 10.1007/s00521-018-3523-0

초록

본 논문에서는 방문자의 쇼핑 의도와 웹 사이트 이탈 가능성을 동시에 예측하는 두 개의 모듈로 구성된 실시간 온라인 쇼퍼 행동 분석 시스템을 제안한다. 첫 번째 모듈에서는 방문 중 추적되는 집계 페이지뷰 데이터와 일부 세션 및 사용자 정보를 이용하여 방문자의 구매 의도를 예측한다. 추출된 특징은 랜덤 포레스트, 서포트 벡터 머신, 다층 퍼셉트론 분류기의 입력으로 사용된다. 분류기의 성능과 확장성을 높이기 위해 오버샘플링과 특징 선택 전처리 단계를 사용한다. 결과는 가중치 백트래킹을 포함한 탄력적 역전파 알고리즘으로 계산한 다층 퍼셉트론이 랜덤 포레스트와 서포트 벡터 머신보다 유의하게 높은 정확도와 F1 점수를 산출함을 보인다. 또 다른 발견은 온라인 방문 중의 이동 경로에서 얻은 클릭스트림 데이터가 방문자의 구매 의도에 관한 중요한 정보를 전달하지만, 구매 관심에 관한 고유 정보를 가진 세션 정보 기반 특징과 결합할 때 시스템의 성공률이 향상된다는 점이다. 두 번째 모듈에서는 순차 클릭스트림 데이터만을 사용하여, 예측 구간 안에서 거래를 완료하지 않고 사이트를 떠나려는 방문자 의도의 확률 추정치를 시그모이드 출력으로 생성하는 장단기 기억 기반 순환 신경망을 학습한다. 두 모듈은 구매 의도는 있으나 예측 구간 안에 사이트를 떠날 가능성이 높은 방문자를 결정하고, 웹 사이트 이탈률과 구매 전환율을 개선하기 위해 적절한 조치를 취하는 데 함께 사용된다. 연구 결과는 클릭스트림 및 세션 정보 데이터를 이용한 가상 쇼핑 환경의 정확하고 확장 가능한 구매 의도 예측이 가능함을 뒷받침한다.

키워드 온라인 쇼퍼 행동 · 장바구니 이탈 · 클릭스트림 데이터 · 딥러닝

번역 작성일: 2026-06-18

1 서론

최근 몇 년 동안 전자상거래 사용이 증가하면서 시장의 잠재력은 커졌지만, 전환율은 같은 속도로 증가하지 않았다. 이 때문에 온라인 쇼퍼에게 맞춤형 프로모션을 제시하는 해결책이 필요해졌다. 오프라인 소매 환경에서는 판매원이 시간이 지나며 얻은 경험을 바탕으로 쇼퍼에게 다양한 맞춤형 대안을 제안할 수 있다. 이러한 경험은 시간의 효율적 사용, 구매 전환율, 판매 수치에 중요한 영향을 준다. 많은 전자상거래 및 정보기술 기업은 가상 쇼핑 환경에서 판매원의 행동을 모방하는 조기 탐지 및 행동 예측 시스템에 투자하고 있다. 이와 병행하여, 학계에서도 기계학습 방법을 이용해 서로 다른 관점에서 이 문제를 다루는 연구들이 제안되어 왔다.

일부 연구는 사용자의 탐색 패턴을 기반으로 방문을 범주화하는 데 초점을 두었고, 다른 연구는 사용자의 행동을 실시간으로 예측하고 그에 따라 조치를 취하여 장바구니 이탈률을 낮추고 구매 전환율을 높이는 것을 목표로 했다.

본 논문에서는 실시간 온라인 쇼퍼 행동 분석 시스템을 제안한다. 제안 시스템은 저자들이 아는 한 처음으로 방문자의 구매 의도와 사이트 이탈 가능성을 동시에 예측하는 두 모듈로 이루어진다. 세션 중 방문자의 구매 의도에 점수를 부여하는 첫 번째 모듈은, 사이트 이탈 가능성을 예측하는 두 번째 모듈의 출력이 미리 정한 임계값보다 큰 경우에만 작동한다. 본 연구에서는 온라인 소매 데이터셋을 사용하고 여러 기계학습 알고리즘의 성능을 서로 다른 조건에서 비교한다.

사용자의 클릭스트림 데이터와 세션 정보를 바탕으로 방문을 범주화하려는 문헌들이 있다. Moe는 특정 온라인 상점의 데이터를 사용해 방문을 범주화하고, 방문 범주에 따라 맞춤형 행동을 취할 수 있는 시스템을 개발할 수 있다고 보았다. 이를 위해 방문의 페이지 간 클릭스트림 데이터에서 특징 집합을 추출하고, k-평균 군집화 알고리즘에 입력하여 구매 가능성에 따라 방문을 분류했다. 얻어진 군집은 직접 구매, 쾌락적 탐색, 지식 구축, 탐색 및 숙고, 얕은 방문으로 명명되었고, 각 군집의 방문자 행동을 분석했을 때 구매 의도가 서로 다르게 나타났다. 직접 구매 군집은 구매를 목적으로 전자상거래 사이트를 방문한 집단이고, 얕은 방문 군집은 두 번의 페이지뷰 후 사이트를 떠나는 방문자 집단을 의미한다.

Mobasher 등은 사용자 거래와 페이지뷰를 기반으로 두 가지 군집화 모델을 구성하여, 추천 시스템이 실시간으로 특정 행동을 취하는 데 효과적으로 사용할 수 있는 집계 사용 프로필을 도출했다. 그 결과 사용자 클릭스트림 데이터에서 추출한 프로필이 가상 쇼핑 환경에서 사용자 방문 초기 단계의 효과적인 개인화에 도움이 될 수 있음을 보였다. 이러한 세션 정보 및 클릭스트림 데이터에서 추출된 특징은 방문자의 의도에 따라 방문을 묶는 데 사용되며, 본 시스템의 첫 번째 모듈에서는 방문자가 거래를 완료할 성향을 추정하는 지도학습 문제를 구성하는 데 사용된다. 따라서 본 연구는 직접 구매 의도를 가지고 전자상거래 사이트를 방문한 사용자를 판별하고, 그들이 거래를 완료하지 않고 사이트를 떠날 가능성이 있을 때만 콘텐츠를 제공한다. 또한 필터 기반 특징 선택 기법을 사용하여 구매 의도 예측에서 가장 판별력 있는 요인을 결정한다.

Suchacka와 Chodak은 웹 서버 로그 데이터를 바탕으로 전자 고객 행동을 특성화했다. 데이터셋은 오픈소스 전자상거래 플랫폼으로 구축된 온라인 서점에서 수집되었다. 전용 C++ 프로그램을 사용해 세션에서 방문한 웹 페이지 수로 나타난 세션 길이, 초 단위 세션 지속 시간, 페이지당 평균 시간, 사용자를 서점 사이트로 유입시킨 페이지를 나타내는 트래픽 유형, 상업적 의도와 관련된 주요 작업을 나타내는 세 가지 이전 변수, 세션 중 조회한 상품 범주 집합 등의 세션 특징을 추출했다. 이들은 연관 규칙 마이닝을 적용하여 방문자의 구매 확률을 평가하고 서로 다른 고객 프로파일의 행동에 대한 유용한 지식을 추출했다.

본 시스템의 첫 번째 모듈과 유사하게, 어떤 연구에서는 구매 의도 예측 문제를 지도학습 문제로 설계하고 온라인 서점에서 수집한 과거 데이터를 이용해 사용자 세션을 탐색 세션과 구매자 세션으로 분류했다. 서로 다른 커널을 가진 서포트 벡터 머신이 분류에 사용되었으며, 이는 본 비교 분석에서도 사용하는 분류기 중 하나다. 같은 데이터셋에 대해 k-최근접 이웃 분류기도 사용되었지만, k-최근접 이웃은 지연 학습 알고리즘이므로 실시간 예측에는 적합하지 않다고 보고 본 연구의 구매 의도 모델링에서는 제외했다.

사용자 행동을 실시간으로 예측하여 맞춤형 행동을 취하려는 문헌들은 대체로 순차 데이터를 사용한다. Budnikas는 가상 쇼핑 환경에서 실시간 행동을 모니터링하고 그에 따라 조치를 취하는 것의 중요성을 지적했다. 그는 사업 목표 달성에 가장 큰 영향을 미치는 웹 사이트 구성 요소를 결정하기 위해 방문자 행동 패턴을 분류하는 방법을 제안했다. 데이터셋은 Google Analytics 추적 코드를 이용해 생성되었으며, 나이트 베이스

와 다층 퍼셉트론 분류기가 웹 사이트 방문자가 거래를 완료하려는지 예측하는 소비자 현장 행동 모델을 만드는 데 사용되었다.

Yeung 또한 전자상거래 사이트에서 방문자의 탐색 경로가 방문자의 행동을 예측하는 데 사용될 수 있음을 보였다. 많은 연구는 세션 중 연속적으로 방문되는 경로의 빈도를 결정하기 위해 은닉 마르코프 모델을 사용한다. 가장 자주 따라가는 탐색 경로는 사용자가 다음 단계에서 방문할 가능성이 높은 웹 페이지를 선택하는 데 사용되고, 이러한 페이지를 추천하여 사용자가 사이트에 머무는 시간을 늘린다.

웹 서버 과부하로 인한 처리량 손실을 고려한 연구에서는 초기 클릭스트림 데이터와 세션 정보를 사용하여 발생할 매출에 따라 세션에 우선순위를 부여하는 시스템을 제안했다. 훈련 데이터셋은 7000건의 거래로 생성되었고, 클래스 불균형 문제를 다루기 위해 절반은 구매 클래스에서 선택되었다. 이들은 마르코프 체인, 로지스틱 선형 회귀, 의사결정나무, 나이브 베이즈를 사용하여 사용자의 구매 의도에 대한 확률을 산출했다.

Ding 등은 방문자의 클릭스트림 데이터를 은닉 마르코프 모델로 모델링하고, 실시간으로 사용자의 의도를 예측하여 이 맥락에서 맞춤형 행동을 취하는 것이 전환율을 높이고 장바구니 이탈률을 낮추는 데 도움이 됨을 보였다. 본 연구에서는 클릭스트림 데이터를 처리하기 위해 은닉 마르코프 모델 대신 장단기 기억 순환 신경망을 사용한다. 이는 시퀀스의 샘플 수가 증가할 때 순환 신경망이 은닉 마르코프 모델보다 더 높은 학습 능력과 일반화 능력을 가진 모델을 생성한다는 결과에 기반한다. 최근 일부 연구가 전자상거래 데이터를 처리하는 데 순환 신경망을 사용했지만, 이들은 사용자의 연속 클릭 이후 추천을 생성하는 세션 기반 추천 시스템에 초점을 두었다. 이와 달리 본 연구는 사용자가 일정 시간 안에 사이트를 떠날 확률을 예측하기 위해 순차 클릭스트림 데이터로 LSTM-RNN을 학습한다.

2 온라인 구매 의도 예측

본 연구에서 구매 의도 모델은 사용자가 거래를 완료할 의도를 측정하는 이진 분류 문제로 설계된다. 따라서 구매하려는 사용자에게만 콘텐츠를 제공하고, 그렇지 않은 사용자에게는 콘텐츠를 제공하지 않는 것을 목표로 한다. 구매 의도 예측 모델에 사용되는 수치형 특징과 범주형 특징은 각각 표 1과 표 2에 제시한다. 데이터셋은 12,330개 세션의 특징 벡터로 구성된다. 데이터셋은 특정 캠페인, 특별한 날, 사용자 프로필 또는 기간에 대한 편향을 피하기 위해 1년 기간 동안 각 세션이 서로 다른 사용자에게 속하도록 구성되었다. 12,330개 세션 중 84.5%인 10,422개는 구매로 끝나지 않은 음성 클래스 표본이고, 나머지 1,908개는 구매로 끝난 양성 클래스 표본이다.

표 1의 Administrative, Administrative duration, Informational, Informational duration, Product related, Product related duration은 해당 세션에서 방문자가 방문한 서로 다른 페이지 유형의 수와 각 페이지 범주에서 보낸 총 시간을 나타낸다. 이러한 값은 사용자가 방문한 페이지의 URL 정보에서 도출되며, 사용자가 한 페이지에서 다른 페이지로 이동하는 등 행동을 취할 때 실시간으로 갱신된다.

Bounce rate, Exit rate, Page value 특징은 전자상거래 사이트의 각 페이지에 대해 Google Analytics가 측정하는 지표를 나타낸다. 개발된 시스템에서는 이 값들을 전자상거래 사이트의 모든 웹 페이지에 대해 애플리케이션 데이터베이스에 저장하고 정기적으로 자동 갱신할 수 있다. 특정 웹 페이지의 Bounce rate는 그 페이지로 사이트에 들어온 방문자가 같은 세션에서 분석 서버에 다른 요청을 일으키지 않고 바로 떠나는 비율을 뜻한다. 특정 웹 페이지의 Exit rate는 그 페이지에 대한 모든 페이지뷰 중 해당 페이지가 세션의 마지막 페이지였던 비율이다. Page value는 전자상거래 거래를 완료하기 전에 사용자가 방문한 웹 페이지의 평균 가치를 나타낸다. Special day 특징은 사이트 방문 시간이 어머니의 날이나 발렌타인데이와 같은 특정 특별한 날에 얼마나 가까운지를 나타내며, 이때 세션이 거래로 마무리될 가능성이 더 높다. 이 속성 값은 주문일과 배송일 사이의 기간 같은 전자상거래의 동적 특성을 고려하여 결정된다.

표 1 사용자 행동 분석 모델에 사용된 수치형 특징

특징 이름	특징 설명	최솟값	최댓값	표준편차
Administrative	방문자가 계정 관리 관련 페이지를 방문한 수	0	27	3.32
Administrative duration	방문자가 계정 관리 관련 페이지에서 보낸 총 시간(초)	0	3398	176.70
Informational	방문자가 쇼핑 사이트의 웹 사이트, 연락처, 주소 정보 관련 페이지를 방문한 수	0	24	1.26
Informational duration	방문자가 정보 페이지에서 보낸 총 시간(초)	0	2549	140.64
Product related	방문자가 상품 관련 페이지를 방문한 수	0	705	44.45
Product related duration	방문자가 상품 관련 페이지에서 보낸 총 시간(초)	0	63,973	1912.25
Bounce rate	방문자가 방문한 페이지들의 평균 반송률	0	0.2	0.04
Exit rate	방문자가 방문한 페이지들의 평균 종료율	0	0.2	0.05
Page value	방문자가 방문한 페이지들의 평균 페이지 가치	0	361	18.55
Special day	사이트 방문 시간이 특별한 날에 가까운 정도	0	1.0	0.19

표 2 사용자 행동 분석 모델에 사용된 범주형 특징

특징 이름	특징 설명	범주 수
OperatingSystems	방문자의 운영체제	8
Browser	방문자의 브라우저	13
Region	세션이 시작된 지리적 지역	9
TrafficType	방문자가 웹 사이트에 도달한 트래픽 출처(예: 배너, SMS, 직접 유입)	20
VisitorType	신규 방문자, 재방문자, 기타로 표시되는 방문자 유형	3
Weekend	방문일이 주말인지 나타내는 불리언 값	2
Month	방문 날짜의 월 값	12
Revenue	방문이 거래로 완료되었는지 나타내는 클래스 라벨	2

2.2 예측

본 연구의 범위에서는 실시간 시스템 사용을 고려하여 k-최근접 이웃과 같은 지연 학습 알고리즘을 방문자의 구매 의도 모델링에서 제외한다. 시스템이 새로운 예제로 갱신되어야 하므로, 온라인 학습 구현이 가능한 다층 퍼셉트론과 의사결정나무 알고리즘을 비교 대상으로 선택했다. 또한 여러 기계학습 응용에서 성공적으로 사용된 서포트 벡터 머신 분류기도 분석에 포함했다. 본 연구에서 사용한 분류 알고리즘의 성능은 정확도, F1 점수, 참양성률과 참음성률 평가 지표를 사용해 비교된다. 실험은 무작위로 선택한 훈련 및 테스트 인스턴스로 100회 반복되었고, 알고리즘의 정확도 차이가 통계적으로 유의한지 검정하기 위해 t 검정을 적용했다.

2.2.1 다층 퍼셉트론

다층 퍼셉트론은 방향 그래프에서 여러 층의 노드로 이루어지며, 각 층이 다음 층과 완전히 연결되는 전방향 인공 신경망 모델이다. 은닉층과 출력층의 요소는 뉴런이라 불리며, 각 뉴런은 처리 단위다. 본 연구의 MLP 모델은 입력층, 출력층, 하나의 은닉층으로 구성된다. MLP는 은닉층의 비선형 활성화 함수를 사용하여 복잡한 비선형 문제를 모델링할 수 있다.

회귀에서 전체 훈련 표본 집합에 대한 오차의 합은 $E(W, v | X) = \sum (rt - yt)^2$ 로 표현된다. 여기서 W 와 v 는 각각 첫 번째 층과 두 번째 층의 가중치 집합이고, T 는 훈련 집합 표본 수, rt 는 표본 t 의 실제 값, yt 는 네트워크 출력, 즉 표본 t 에 대한 예측값이다. 네트워크 출력은 은닉 노드 출력과 두 번째 층 가중치의 합으로 계산되며, 이진 분류 문제에서는 출력 yt 가 시그모이드 함수를 통과한다.

층 사이 연결을 나타내는 가중치인 신경망의 매개변수는 훈련 과정에서 반복적으로 학습된다. 가중치 W 와 v 는 학습 알고리즘의 규칙에 따라 갱신된다. 네트워크를 훈련하는 전통적 알고리즘은 역전파이며, 식 (1)의 오차 함수의 국소 최솟값을 찾기 위해 신경망 가중치를 갱신한다. 두 번째 층의 MLP는 은닉 뉴트를 입력으로 하는 단순 퍼셉트론이므로 최소제곱 규칙으로 두 번째 층 가중치를 갱신한다.

반면 첫 번째 층 가중치의 경우 은닉 뉴런에 대한 원하는 출력이 제공되지 않기 때문에 최소제곱 규칙을 직접 적용할 수 없다. 따라서 오차는 출력에서 입력으로 연쇄 법칙을 이용해 역전파된다. 가중치는 국소 최솟값에 도달할 때까지 편미분의 반대 방향으로 갱신된다.

본 연구에서는 신경망을 계산하기 위해 가중치 백트래킹을 포함한 탄력적 역전파 알고리즘을 사용한다. 탄력적 역전파는 신경망 훈련에 사용되는 가장 빠른 알고리즘 중 하나로 알려져 있다. 전통적 역전파는 모든 가중치에 하나의 학습률을 갖지만, 탄력적 역전파에서는 훈련 과정에서 수정될 수 있는 별도의 학습률이 각 가중치에 사용된다. 이 방식은 전체 훈련 과정과 전체 네트워크에 적합한 전역 학습률을 정해야 하는 문제를 완화한다. 또한 탄력적 역전파에서는 편미분의 부호만 가중치 수정에 사용하므로 학습률이 전체 네트워크에 균등한 영향을 미친다.

학습 과정에서 해당 편미분이 같은 부호를 유지하면 학습률 값을 증가시키고, 오차 함수의 편미분 부호가 바뀌면 학습률을 감소시킨다. 이를 적응적 학습률이라고 한다. 실험에서 사용한 가중치 백트래킹 메커니즘은 마지막 반복을 되돌리고 다음 단계에서 더 작은 값을 가중치에 더하여, 이후 반복에서 다시 최솟값을 지나치는 것을 방지한다. 본 연구에서는 은닉층의 은닉 뉴런 수를 달리한 결과를 제시한다. 반복 횟수는 오차 함수 편미분의 임계값 0.2를 중지 기준으로 사용하여 동적으로 결정된다.

2.2.2 서포트 벡터 머신

서포트 벡터 머신 분류기는 여러 문헌에서 분류 능력이 입증되었으므로 본 분석에 포함된다. SVM은 온라인 학습을 위한 직접적인 구현이 간단하지는 않지만, 본 연구의 다른 분류기보다 유의하게 높은 정확도를 달성한다면 새로운 예제로 SVM 모델을 동적으로 갱신하는 온라인 수동-공격적 구현을 사용할 수 있다.

SVM은 클래스를 서로 구분하기 위한 최적 분리 경계인 초평면을 찾는 것을 목표로 하는 판별 기반 알고리즘이다. 이 초평면에 가장 가까운 표본을 서포트 벡터라고 하며, 판별식은 이 표본 부분집합의 가중합으로 표현되어 문제 복잡도를 제한한다. 최적 분리 초평면을 찾기 위한 최적화 문제는 가중치 벡터, 정규화 매개변수, 슬랙 변수, 실제 클래스 값을 사용해 정의된다. 슬랙 변수는 훈련 집합의 오차를 허용하여 과적합을 피하고 모델의 일반화 능력을 향상시키기 위해 정의된다.

정규화 매개변수 C 는 데이터에 적합되는 모델의 복잡도를 제어하는 알고리즘의 하이퍼파라미터다. C 값이 클수록 훈련 집합 인스턴스에 대한 모델의 허용 오차가 작아져 훈련 집합에 과적합될 수 있다. SVM은 선형 분류기이지만 커널 함수를 사용하여 원래 입력 공간을 더 높은 차원의 특징 공간으로 매핑함으로써 비선형 상호작용을 모델링할 수 있다. 본 연구에서는 선형 커널과 방사 기저 함수 커널을 사용한다. 하이퍼파라미터 C 와 방사 기저 함수의 폭 매개변수는 임의로 선택한 하나의 훈련/검증 분할에서 그리드 탐색으로 최적화하고, 정해진 값을 나머지 분할에 사용한다. 실험 분석에는 LIBSVM 구현을 사용했다.

2.2.3 의사결정나무

방문자의 상업적 의도를 예측하는 다른 분류기는 의사결정나무 알고리즘의 변형이다. 의사결정나무는 분류와 회귀에 모두 사용할 수 있는 효율적인 비모수 방법이다. 의사결정나무는 내부 의사결정 노드와 말단 리프라는 두 가지 주요 구성 요소를 가진다. 각 내부 노드는 하나 이상의 특징을 사용해 테스트 함수를 구현하고, 해당 노드에서 내려가는 각 가지는 대응하는 이산 결과로 표시된다.

테스트 시 새로운 인스턴스가 주어지면 루트 노드가 지시하는 테스트가 인스턴스에 적용되고, 의사결정 노드의 출력에 따라 다음에 방문할 내부 노드가 결정된다. 이 과정은 주어진 테스트 인스턴스에 대한 구성된 트리의 출력인 리프 노드에 도달할 때까지 반복된다. 본 논문에서는 개별 의사결정나무 분류기를 만들기 위해 C4.5 알고리즘을 사용한다. C4.5 알고리즘은 수치 속성을 허용하고, 결측값을 처리하며, 구성 이후 가지 치기를 수행함으로써 ID3 트리 구성 알고리즘을 확장했다.

랜덤 포레스트는 배경 재표본화 기법을 사용하여 다양하고 정확한 분류나무 집합을 구성하고, 개별 나무의 예측을 투표 전략으로 결합하는 방식에 기반한다. 원래 훈련 집합의 N 개 인스턴스에서 복원 추출로 N 개 인스턴스를 선택하여 하위 표본을 만들고, 각 노드에서는 전체 M 개 입력 변수 중 훨씬 작은 m 개 변수를 무작위로 선택하여 그중 최선의 분할을 사용한다. 각 트리는 미리 정한 중지 기준에 따라 가지치기 없이 가능한 한 크게 성장하며, 원하는 수의 나무가 만들어질 때까지 이 과정을 반복한다. 본 실험에서는 m 을 $\log_2(M)$ 으로 설정하고, 각 배그의 크기는 N , 포레스트의 나무 수는 100으로 설정했다.

2.3 필터 기반 특징 선택

분류 성능 및 시스템 확장성을 개선하기 위해 특징 선택 기법을 적용한다. 더 적은 수의 특징으로 더 좋거나 유사한 분류 성능을 달성할 수 있는지 조사하는 것이 목표다. 차원 축소를 위해 주성분 분석과 같은 특징 추출 기법을 사용할 수도 있지만, 이 경우 축소 공간의 특징은 17개 속성의 선형 결합이 되므로 방문 중 모든 특징을 추적하고 방문자가 새로운 행동을 취한 뒤 특징 벡터를 갱신해야 한다. 따라서 본 연구에서는 특징 추출 대신 특징 선택을 적용하는 것이 적절하다고 보았다.

특징 순위화에는 특정 학습 알고리즘을 반복적으로 사용해야 하여 해당 분류기에 특화된 축소 특징 집합을 만들 수 있는 래퍼 알고리즘 대신 필터 기반 특징 선택을 적용했다. 실험에서는 상관계수, 상호정보량, mRMR 필터를 사용한다. 상호정보량은 두 변수 사이의 상호 의존성을 측정하는 지표다. 상관계수는 선형 관계만 포착할 수 있지만, 상호정보량은 비선형 관계도 포착할 수 있다. 상호정보량은 확률변수의 불확실성 척도인 Shannon 엔트로피에 기반한다.

상호정보량 기반 특징 선택에서는 먼저 각 특징과 클래스 라벨 사이의 상호정보량 점수를 계산한다. 그런 다음 특징을 상호정보량 점수의 내림차순으로 정렬하고 상위 n 개 특징을 학습 알고리즘에 입력한다. 본 연구의 데이터셋 특징 중 일부는 연속형 변수이므로, 상호정보량이 이산 변수에 대해 정의된다는 점을 고려해 연속형 변수를 이산화해야 한다. 실험에서는 각 특징을 9개 이산 수준으로 나누는 구간화 절차를 사용한다.

상관계수와 상호정보량 필터에 더해 mRMR 알고리즘도 특징 부분집합 선택에 사용한다. mRMR 알고리즘의 목표는 선택된 특징 집합과 클래스 변수 사이의 관련성을 최대화하면서 선택된 특징 사이의 중복성을 피하는 것이다. 따라서 최소 특징 부분집합으로 최대 분류 정확도를 얻는 것을 목표로 한다. 후보 특징과 클래스 변수 사이의 상호정보량으로 계산한 관련성 항은, 후보 특징과 이미 선택된 변수들 사이의 평균 상호정보량으로 계산한 중복성 항만큼 할인된다. 이 두 항의 차이는 후보 변수가 목표 변수에 대해 갖는 고유 정보량으로 볼 수 있다.

3 이탈 가능성 예측

제안 시스템에서 방문 중 콘텐츠를 제공할지 결정하는 알고리즘은 사용자가 구매하지 않고 사이트를 떠날 가능성이 있을 때에만 작동한다. 이러한 이탈 분석을 위해, 예측 구간이라고 부를 수 있는 특정 기간 안에 사이트를 떠날 방문자를 미리 예측하는 장단기 기억 순환 신경망 모델을 구성한다. 이를 위해 방문 중 사용자가 수행하는 각 페이지뷰 행동에 대해 페이지 유형과 해당 페이지에서 보낸 시간을 특징 벡터로 사용한다.

3.1 데이터셋 설명

순환 신경망 기반 이탈 분석 모듈에 사용된 데이터셋은 3500명 방문자의 9800개 세션에서 방문된 185,000개 웹 페이지를 포함한다. 이 데이터셋에서는 URL 정보에서 상품 조회, 관리 작업, 정보 획득 작업 유형의 행동이 추출되었다. 또한 이탈 분석에 매우 중요한 정보를 담고 있다고 여겨지는 장바구니 작업을 별도 행동 유형으로 사용했다. 1-of-C 코딩으로 얻은 네 개의 이진 값으로 표현되는 페이지 유형 정보에 더해, 해당 페이지에서 보낸 시간도 특징으로 사용된다. 방문 중 이러한 행동 중 하나가 발생한 뒤 이 특징 벡터가 생성되고, 순차 데이터를 처리하기 위해 LSTM-RNN에 입력된다.

3.2 RNN 기반 이탈 분석 모듈

전통적인 다층 퍼셉트론은 전방향 연결만 가지지만, 순환 신경망의 유닛은 전방향 연결, 자기 연결, 이전 층의 유닛과의 연결을 가진다. 순환 신경망은 현재 입력 인스턴스뿐 아니라 시간상 이전에 지각한 내용을 입력으로 사용하므로 순차 정보를 활용할 수 있다. 입력 시퀀스 X 가 주어지면 시점 t 의 순환 은닉 상태는 현재 입력과 이전 은닉 상태의 함수로 갱신된다. 전통적 접근에서는 입력-은닉 가중치 행렬, 상태-상태 순환 가중치 행렬, 은닉층 함수를 사용하여 순환 은닉 상태를 갱신한다. 은닉층 함수로는 로지스틱 시그모이드 또는 하이퍼볼릭 탄젠트처럼 부드럽고 유계인 함수를 사용한다.

순환 신경망은 필기, 유전체, 음성, 이미지, 주식시장과 같은 순차 또는 시계열 데이터에서 패턴을 인식하는 데 성공적으로 적용되어 왔다. 또한 시간 시퀀스를 처리하는 응용 외에도, 훈련이 필요 없는 모델 기반 순환 신경망이 중복 매니플레이터 제어 같은 다양한 문제에 성공적으로 적용되었다. 이론적으로 순환 신경망은 장기 의존성을 처리하도록 설계되었지만, 많은 시간 단계에 걸쳐 역전파할 때 발생하는 기울기 소실 문제 때문에 멀리 떨어진 단계 사이의 의존성을 학습하기 어렵다는 점이 알려져 있다.

이 문제를 극복하기 위해 Hochreiter와 Schmidhuber는 은닉층의 각 전통적 노드를 메모리 셀과 세 종류의 게이트로 구성된 LSTM 유닛으로 대체하는 장단기 기억 구조를 제안했다. 게이트는 셀의 상태를 보호하고 제어하기 위해 포함된다. 입력 게이트는 최신 내용 중 얼마나 많이 기억할지를 제어하고, 망각 게이트는 기존 기억을 얼마나 잊을지를 조절한다. 출력 게이트는 메모리 내용이 얼마나 노출될지를 제어한다.

이탈 분석 모듈의 목적은 사용자가 종료 행동에 들어가기 전에 탐색 클릭스트림 데이터를 이용해 사이트를 곧 떠날지를 예측하는 것이다. 전자상거래 사이트 방문 중 방문자의 탐색 경로가 사용자의 다음 행동을 예측하는 데 사용될 수 있다는 관련 문헌의 결과를 바탕으로, 본 연구는 순차 페이지뷰 패턴을 시계열 데이터로 처리하고 방문자가 일정 기간 안에 사이트를 떠날지를 예측한다. 관련 연구 대부분은 이 문제를 은닉 마르코프 모델로 다루지만, 본 연구는 각 세션에서 방문한 평균 웹 페이지 수와 시퀀스 표본 수가 증가할수록 순환 신경망이 더 높은 학습 능력과 일반화 능력을 갖는다는 점을 고려하여 LSTM-RNN 모델을 구성한다.

훈련 단계에서는 은닉 마르코프 모델이 순환 신경망보다 확장성이 더 좋을 수 있다. 그러나 본 연구에서는 GPU 구현을 사용하여 순환 신경망 훈련의 확장성을 개선한다. 실시간 예측에서는 사용자 행동 후 테스트만 수행되며, 시스템은 활성 시간이 아닌 시간에 온라인 학습 구현으로 새로운 예제를 이용해 동적으로 갱신되도록 계획되어 있으므로 LSTM-RNN의 사용이 가능하다. LSTM-RNN의 효과를 보이기 위해 전체 정확도를 MLP, 극한 학습 기계, 방사 기저 함수라는 세 가지 다른 신경망 모델과 비교한다. 이들 모델에서는 방문자의 마지막 세 행동 사이의 의존성을 모델링하기 위해 시간 지연 접근법을 사용한다.

4 제안 시스템

제안 시스템의 활동 다이어그램은 그림 1에 제시된다. 랜딩 페이지에서 시작하여 구매 의도 및 이탈 모듈에 사용할 특징 값이 각 페이지뷰 후 추적되고 갱신된다. 갱신된 특징 벡터는 LSTM-RNN 테스트 스크립트에 입력되고, 이 스크립트는 거래를 완료하지 않고 사이트를 떠나려는 방문자의 의도에 대한 확률 추정치를 시그모이드 출력으로 생성한다. 이 모듈의 출력이 미리 정한 임계값보다 크면 MLP 스크립트의 시그모이드 출력을 확인한다. MLP 출력이 미리 정한 임계값, 기본값 0.5보다 크면 방문자가 탐색을 계속하고 거래를 완료하도록 콘텐츠를 제공한다.

전자상거래 웹 사이트 이탈 분석에서는 효과적인 학습 문제를 설계하기 위해 방문자가 최소 세 페이지를 표시해야 한다고 문헌에서 제시되었다. 이 결과에 근거하여 RNN 모델의 단계 크기를 3으로 설정했다. 본 LSTM-RNN 네트워크는 30개의 뉴런을 포함하는 하나의 은닉층으로 구성된다. 시스템은 지도학습 문제로 설계되지만, 예측 구간을 정의하는 방식에는 여러 접근을 고려할 수 있다. 본 연구에서는 데이터셋에서 방문자가 사이트에 머무르는 전체 초 수의 분포를 분석한 결과에 따라, 방문자가 웹 사이트를 떠나기 전에 수행할 페이지뷰 행동 수로 예측 구간을 정의하는 방식을 선택했다.

그림 1 제안 시스템의 활동 다이어그램

방문자	행동 분석 모듈	이탈 분석 모듈
랜딩 페이지	세션 및 개인 정보를 검색하고 사용자 프로필을 갱신	페이지뷰 후 특징 벡터를 LSTM-RNN 테스트 스크립트에 입력
새 행동 발생	MLP 테스트 스크립트로 구매 의도 시그모이드 출력 계산	예측 구간 안에 사이트 이탈 가능성 판단
콘텐츠 제안 조건	구매 의도 출력이 임계값보다 크면 콘텐츠 표시	이탈 가능성 출력이 임계값보다 클 때만 구매 의도 모듈 호출
종료	콘텐츠 표시 또는 세션 종료까지 반복	세션 종료까지 반복

알고리즘 1 사용자 행동 분석

단계	내용
입력	초기 클릭스트림 데이터 X1, 세션 정보 데이터 X2, 이탈 임계값 a1, 구매 의도 임계값 a2
1	방문자가 수행하는 각 행동에 대해 반복한다.
2	X1을 갱신한다.
3	X1의 각 열을 표준화한다.
4	$s1 = \text{LSTM-RNN}(X1)$: 이탈 가능성을 추정한다.
5	$s1 > a1$ 이면 방문자가 예측 구간 안에 사이트를 떠날 가능성이 있다고 판단한다.
6	$s2 = \text{MLP}(X1, X2)$: 구매 의도를 추정한다.
7	$s2 > a2$ 이면 방문자가 구매 의도를 가진다고 판단한다.
8	방문자에게 콘텐츠를 표시한다.
9	방문자가 세션을 종료할 때까지 반복한다.

4.1 구매 의도 예측

전처리 단계로 범주형 변수는 1-of-C 코딩으로 매핑되고, 수치형 특징은 평균 0과 단위 분산으로 표준화된다. 그런 다음 데이터셋의 70%를 훈련에 사용하고 나머지를 검증에 사용하여 의사결정나무, 서포트 벡터 머신, 다층 퍼셉트론 분류기에 입력한다. 통계적 유의성을 위해 이 절차는 임의의 훈련/검증 분할로 100회 반복되며, 각 알고리즘의 성능이 서로 통계적으로 다른지 확인하기 위해 t 검정을 적용한다. 각 분류기에 대해 평균 정확도, 참양성률, 참음성률, F1 점수를 제시한다.

4.1.1 클래스 불균형 데이터셋에서의 결과

표 3, 표 4, 표 5는 각각 의사결정나무, MLP, SVM 알고리즘을 테스트 집합에 적용한 결과를 보여준다. 결과에 따르면 C4.5 의사결정나무 구현이 테스트 집합에서 가장 높은 정확도를 보인다. 그러나 데이터셋에서 음성 클래스 인스턴스 수가 양성 클래스보다 훨씬 많기 때문에 클래스 불균형 문제가 발생한다. 양성 표본과 음성 표본에 대한 불균형 성공률은 분류기들이 테스트 표본을 다수 클래스에 속한다고 표시하는 경향을 보인다.

이러한 클래스 불균형은 대부분의 전자상거래 방문이 구매로 끝나지 않기 때문에 분석 문제에서 자연스럽게 나타난다. 따라서 분류기의 성능을 평가할 때 전체 정확도뿐 아니라 F1 점수처럼 클래스 불균형을 고려하는 대체 지표를 사용해야 한다. 본 연구에서는 표에 보이는 것처럼 일반 정확도, 개별 클래스 정확도, F1 점수를 함께 보고한다. 가장 높은 F1 점수 0.58은 범주형 변수를 1-of-C 코딩으로 매핑하여 얻은 입력층 70개 뉴런과 은닉층 20개 뉴런을 가진 MLP에서 얻어졌다. 반면 가장 낮은 F1 점수 0.52는 선형 커널 SVM에서 얻어졌다. 표 5에서 볼 수 있듯, 선형 커널 SVM은 RBF 커널 SVM보다 유의하게 높은 정확도를 제공하지만, RBF 커널 SVM은 양성 및 음성 표본에서 더 균형 잡힌 분류율을 생성한다.

표 3 테스트 집합에서 의사결정나무 기반 분류기로 얻은 결과

분류기	정확도(%)	TPR	TNR	F1 점수
C4.5	88.92	0.57	0.96	0.57
랜덤 포레스트	89.51	0.57	0.96	0.58

표 4 테스트 집합에서 다층 퍼셉트론으로 얻은 결과

은닉층 뉴런 수	정확도(%)	TPR	TNR	F1 점수
10	87.45	0.53	0.94	0.56
20	87.92	0.56	0.96	0.58
40	87.02	0.54	0.93	0.56

표 5 테스트 집합에서 서포트 벡터 머신으로 얻은 결과

커널	정확도(%)	TPR	TNR	F1 점수
선형	88.25	0.42	0.97	0.52
RBF	86.14	0.46	0.92	0.53

참고: 논문 표의 별표는 통계적 유의성을 나타낸다. **p < 0.01, *p < 0.05.

4.1.2 오버샘플링으로 얻은 결과

앞 절의 결과는 분류기가 다수 클래스 표본의 오류를 최소화하는 경향이 있으며, 이로 인해 양성 클래스와 음성 클래스의 정확도 사이에 불균형이 생김을 보여준다. 그러나 실시간 사용자 행동 분석 모델에서는 데이터셋에서 양성 클래스로 표현되는 직접 구매 방문을 올바르게 식별하는 것이 음성 클래스 표본을 식별하는 것만큼 중요하다. 따라서 전자상거래 웹 사이트의 전환율을 높이려면 균형 잡힌 분류기가 필요하다.

클래스 불균형 문제를 다루기 위해 본 연구는 소수 클래스 인스턴스를 더 많이 추가하여 클래스에 대한 균일 분포를 달성하려는 오버샘플링 방법을 사용한다. 소수 클래스 인스턴스가 여러 번 선택되어 데이터셋이 생성되므로, 먼저 전체 데이터셋을 오버샘플링한 뒤 훈련 집합과 테스트 집합으로 나누면 같은 소수 클래스 인스턴스가 훈련과 테스트에 모두 사용될 수 있어 편향된 결과가 생길 수 있다. 따라서 본 연구에서는 12,330개 표본으로 이루어진 데이터셋의 30%를 먼저 테스트용으로 남겨두고, 나머지 70% 표본에 오버샘플링을 적용한다.

균형 데이터셋에서 얻은 결과는 표 6, 표 7, 표 8에 제시된다. 오버샘플링으로 양성 및 음성 클래스 표본 수가 같아졌으므로 정확도와 F1 점수를 모두 결과 평가에 사용할 수 있다. 가장 높은 정확도 87.24%와 F1 점수 0.86은 은닉층에 10개 뉴런을 가진 MLP에서 얻어졌다. 모든 알고리즘의 최적 설정으로 얻은 결과 요약은 표 9에 제시된다. RBF 커널 SVM은 C4.5 의사결정나무 구현보다 유의하게 높은 정확도를 보였다.

표 6 오버샘플링 데이터셋에서 의사결정나무 기반 분류기로 얻은 테스트 결과

분류기	정확도(%)	TPR	TNR	F1 점수
C4.5	82.34	0.79	0.85	0.82
랜덤 포레스트	82.29	0.74	0.90	0.81

표 7 오버샘플링 데이터셋에서 다층 퍼셉트론으로 얻은 테스트 결과

은닉층 뉴런 수	정확도(%)	TPR	TNR	F1 점수
10	87.24	0.84	0.92	0.86
20	83.84	0.84	0.83	0.83
40	82.15	0.82	0.83	0.82

표 8 오버샘플링 데이터셋에서 서포트 벡터 머신으로 얻은 테스트 결과

커널	정확도(%)	TPR	TNR	F1 점수
선형	84.26	0.75	0.93	0.82
RBF	84.88	0.75	0.94	0.82

표 9 본 연구에서 사용한 분류기들의 최고 결과 요약

분류기	정확도(%)	TPR	TNR	F1 점수
C4.5	82.34	0.79	0.85	0.82
MLP	87.24	0.84	0.92	0.86
RBF SVM	84.88	0.75	0.94	0.82

4.1.3 특징 선택

가장 높은 정확도와 F1 점수를 달성한 MLP 알고리즘을 직접 구매 방문 식별에 선택했다. 이 절에서는 MLP 분류기의 분류 성능을 더 개선하기 위해 특징 선택을 적용한다. 또한 제안 시스템의 실시간 사용을 고려하면, 더 적은 수의 특징으로 더 좋거나 유사한 분류 성능을 달성하는 것은 세션 중 추적해야 하는 특징 수를 줄여 시스템 확장성을 개선한다.

표 10은 본 연구에서 사용한 필터로 얻은 특징 순위를 보여준다. 결과에 따르면 Google Analytics 추적 도구의 Page value 특징은 모든 필터에서 첫 번째로 선택되었고 방문자의 의도에 관한 판별 정보를 갖고 있다. Page value는 전자상거래 거래를 완료하기 전에 사용자가 방문한 페이지의 평균 가치를 나타내므로, 방문자의 거래 완료 의도를 나타내는 자연스러운 척도로 볼 수 있다. 본 시스템에서는 이 특징이 세션 중 방문자가 방문한 페이지들의 Page value 평균으로 표현되고, 방문자가 다른 페이지로 이동할 때 갱신된다.

다른 두 Google Analytics 특징인 Exit rate와 Bounce rate도 클래스 변수와 높은 상관을 보이며 상관계수 및 상호정보량 필터 순위에서 상위에 위치한다. 그러나 Bounce rate는 Exit rate와도 높은 상관을 가져 중복 정보를 포함하므로, 최대 관련 변수는 점진적으로 선택하면서 중복 변수는 피하는 mRMR에서는 15번째로 선택된다. 마찬가지로 Product related와 Product related duration 속성은 클래스 변수와 밀접히 관련되어 있지만, 알고리즘이 이미 선택한 Page value 특징과 높은 상관을 가지기 때문에 mRMR에서는 마지막 순위로 배치된다. 상관계수와 상호정보량 필터는 선택된 변수들 사이의 관계를 무시하므로 유사한 순위를 제공하지만, mRMR 방법은 이들과 상당히 다른 순위를 산출한다.

각 필터에서 선택된 상위 10개 특징은 오버샘플링 데이터셋을 사용하여 MLP 알고리즘에 점진적으로 입력된다. 각 방법에서 얻은 최고 정확도와 해당 MLP 모델의 입력 변수 수는 표 11에 제시된다. 가장 높은 정확도 87.94%와 F1 점수 0.87은 mRMR 순위의 상위 6개 특징을 포함하는 특징 부분집합을 사용했을 때 얻어졌다. 이 값들은 다른 두 방법의 최고 정확도 및 F1 점수와 통계적으로 다르다. 또한 상관계수와 상호정보량 필터는 최적 모델에서 mRMR보다 더 많은 특징을 사용한다. mRMR 필터가 더 적은 특징으로도 유의하게 더 높은 정확도를 보였으므로, 실시간으로 특징 벡터를 주기적으로 저장하고 갱신해야 하는 확장성까지 고려하여 mRMR로 선택된 상위 6개 특징을 입력으로 하는 MLP를 최종 모델로 결정했다.

표 10 필터 특징 선택 방법으로 얻은 특징 순위

순위	상관계수	상호정보량	mRMR
1	Page value	Page value	Page value
2	Exit rate	Exit rate	Month
3	Product related	Product related duration	Exit rate

순위	상관계수	상호정보량	mRMR
4	Product related duration	Bounce rate	Weekend
5	Bounce rate	Product related	Informational duration
6	Administrative	Traffic type	Region
7	Visitor type	Administrative	Operating system
8	Informational	Month	Administrative
9	Administrative duration	Administrative duration	Visitor type
10	Special day	Informational	Product related duration
11	Month	Informational duration	Special day
12	Traffic type	Visitor type	Informational
13	Informational duration	Special day	Traffic type
14	Operating system	Operating system	Administrative
15	Weekend	Browser	Bounce rate
16	Region	Weekend	Browser
17	Browser	Region	Product related

표 11 상위 순위 특징을 MLP 입력으로 사용했을 때 얻은 최고 결과

필터	특징 수	정확도(%)	TPR	TNR	F1 점수
상관계수	9	84.32	0.84	0.85	0.84
상호정보량	10	84.11	0.84	0.85	0.84
mRMR	6	87.94	0.84	0.92	0.87

4.2 이탈 가능성 예측

4절에서 언급했듯이, 효과적인 학습 문제를 설계하기 위해 방문자가 표시해야 하는 최소 페이지 수는 문헌에서 3으로 결정되었다. 이 결과에 근거하여 LSTM-RNN 모델의 단계 크기를 3으로 설정했다. LSTM-RNN 외에도 MLP, 극한 학습 기계, 방사 기저 함수라는 세 가지 신경망 모델의 결과를 제시한다. 이 모델들은 방문자가 방문한 웹 페이지 유형과 해당 페이지에서 보낸 시간이라는 현재 입력을, 마지막 두 웹 페이지의 유형과 각 웹 페이지에서 보낸 시간이라는 지연 입력 사본과 결합하는 시간 지연 접근법으로 구성된다. MLP, ELM, RBF 모델의 은닉층 뉴런 수는 각각 10, 75, 8이다.

그림 2는 방문자가 웹 사이트를 떠나기 전에 수행할 행동 수로 결정되는 예측 구간에 따라 테스트 집합에서 얻은 전체 정확도와 참양성률을 보여준다. 테스트 집합은 모든 예측 구간 값에 대해 양성 및 음성 표본 수가 같도록 구성되었다. 그림 2에서 볼 수 있듯, LSTM-RNN 모델은 사용자가 한 번의 행동 후 웹 사이트를 떠날 것을 74.3% 정확도로 올바르게 예측한다. 또한 모든 예측 구간 설정에서 LSTM-RNN은 다른 신경망 유형보다 유의하게 높은 정확도를 산출한다.

예측 구간이 증가할수록 사용자의 최종 이탈 결정까지의 시간과 행동 수가 증가하므로 이탈 예측 모델의 성공률은 감소한다. 사용자가 콘텐츠를 제공받아야 하는지를 결정하는 MLP 모델은, 최소 세 페이지가 방문된 뒤 RNN 기반 이탈 분석 모델의 출력이 임계값을 초과할 때 작동한다. 다양한 임계값에 대해 LSTM-RNN으로 얻은 참양성률을 보면, 예측 구간을 2, 임계값을 0.90으로 설정했을 때 최대 참양성률 0.94가 달성된다. 임계값이 증가할수록 시스템이 긍정 예측을 드물게 생성하므로 캠페인을 제안하려는 경향은 감소한다.

그림 2 이탈 예측 모델의 결과

항목	한국어 설명
왼쪽 그래프	LSTM-RNN, 다층 퍼셉트론, 극한 학습 기계, 방사 기저 함수 네트워크가 예측 구간 안에 방문자가 사이트를 떠날지 예측할 때의 전체 정확도
오른쪽 그래프	예측 구간 및 임계값의 다양한 값에 대해 LSTM-RNN 네트워크가 산출한 참양성률
주요 관찰	LSTM-RNN은 모든 예측 구간에서 비교 신경망보다 높은 정확도를 보였고, 예측 구간이 길어질수록 예측 난도와 오류 가능성이 증가했다.

5 결론

본 논문에서는 두 개의 모듈로 구성된 가상 쇼핑 환경용 실시간 사용자 행동 분석 시스템을 구축했다. 실험에는 온라인 소매 데이터를 사용했다. 첫 번째 모듈에서는 방문자의 구매 의도를 예측하기 위해 방문 중 추적되는 집계 페이지뷰 데이터와 일부 세션 및 사용자 정보를 기계학습 알고리즘의 입력으로 사용했다. 알고리즘의 성공률과 확장성을 개선하기 위해 오버샘플링과 특징 선택 전처리 기법을 적용했다. 가장 좋은 결과는 가장치 백트래킹을 포함한 탄력적 역전파를 사용하여 계산한 다층 퍼셉트론 네트워크에서 얻어졌다.

두 번째 모듈에서는 순차 클릭스트림 데이터만을 사용하여 장단기 기억 기반 순환 신경망을 학습했다. 이 신경망은 예측 구간 안에서 거리를 완료하지 않고 사이트를 떠나려는 방문자의 의도에 대한 확률 추정치를 시그모이드 출력으로 생성한다. 두 모듈은 방문자의 구매 의도와 사이트 이탈 가능성을 동시에 예측한다. 첫 번째 모듈은 두 번째 모듈이 미리 정한 임계값보다 큰 값을 생성할 때에만 작동하며, 이에 따라 시스템은 방문 중 콘텐츠를 제공할지를 결정한다. 따라서 본 연구는 구매 의도가 있으면서 예측 구간 안에 사이트를 떠날 가능성이 높은 방문자를 결정하고, 그러한 방문자에게만 콘텐츠를 제공하는 것을 목표로 한다.

연구 결과는 방문 중 클릭스트림 데이터에서 추출한 특징이 온라인 구매 의도 예측에 중요한 정보를 전달한다는 주장을 뒷받침한다. 방문 중 얻은 클릭스트림 데이터의 집계 통계를 나타내는 특징은 필터 특징 순위화 알고리즘에서 상위에 배치된다. 그러나 이러한 지표들은 서로 높은 상관을 가진다. 반면 세션 정보 기반 특징은 방문자의 구매 의도와 상관은 상대적으로 낮지만 클릭스트림 기반 특징과 다른 고유 정보를 포함한다. 따라서 특징 간 중복성을 고려하는 최소 중복-최대 관련성 특징 순위화 방법을 적용했다. 결과는 클릭스트림 데이터 집계 통계와 방문 날짜 및 지리적 지역 같은 세션 정보의 최소 조합을 선택하는 것이 더 정확하고 확장 가능한 시스템을 만든다는 것을 보인다.

제안 시스템의 실시간 사용을 고려하면, 최소 특징 부분집합으로 더 좋거나 유사한 분류 성능을 달성하는 것은 세션 중 더 적은 수의 특징을 추천하면 되므로 중요한 요소로 볼 수 있다. 제안 시스템의 두 번째 모듈에서는 순차 클릭스트림 데이터만을 사용해 LSTM-RNN을 학습하여 사용자가 정해진 예측 구간 안에 사이트를 떠날 확률을 예측한다. 예측 구간은 방문자가 웹 사이트를 떠나기 전에 수행할 페이지뷰 행동 수로 결정된다. 중요한 관찰은 예측 구간이 증가할수록 사용자의 최종 이탈 결정까지의 시간과 행동 수가 증가하여 추정이 더 어려워지고 성공률이 감소한다는 점이다. 양성 예제 예측의 최대 정확도는 예측 구간을 두 페이지뷰로 설정했을 때 달성된다. 향후 연구 방향으로, 구매 의도가 있고 예측 구간 안에 사이트를 떠날 가능성이 높은 사용자에게 사용자별 콘텐츠를 제공하여 전환율을 더 높일 수 있도록 아이템 기반 또는 사용자 기반 추천 시스템을 통합할 수 있다.

감사의 글: 저자들은 데이터 공유에 도움을 준 Gózálan Group과 이 과정 전반에 도움을 준 Inveon analytics 팀에 감사를 표한다. 연구비: 본 연구는 TUBITAK-TEYDEB 프로그램의 프로젝트 번호 3150945의 지원을 받았다. 윤리 기준 준수: 저자들은 이해 상충이 없음을 선언한다.